

EXPLICABILIDADE EM IA

conceitos básicos

Explicabilidade em IA

Inteligência Artificial Explicável (XAI) é aquela que produz detalhes ou razões para tornar seu funcionamento claro ou fácil de entender por um determinado público.



PL 2338/2023

visa estabelecer o marco
regulatório para o desenvolvimento
e uso de inteligência artificial no
Brasil

Explicabilidade em IA

O termo foi usado pela primeira vez em 2004 por Van Lent et al., para descrever a capacidade de seu sistema de explicar o comportamento de entidades controladas por IA em aplicações de jogos de simulação.

Embora o termo seja relativamente novo, o problema da explicabilidade existe desde meados dos anos 1970, quando pesquisadores estudavam explicações para sistemas especialistas.

Diferença entre explicabilidade e interpretabilidade

INTERPRETABILIDADE	EXPLICABILIDADE
Refere-se à capacidade de compreender como um modelo de IA toma suas decisões.	Envolve a capacidade de explicar essas decisões de uma maneira que seja compreensível para os usuários humanos.


Estrutura de uma Explicação



Estrutura de uma Explicação



Grupo de usuários



Estrutura de uma Explicação



Objetivos da Explicabilidade

A explicabilidade deve responder a várias perguntas para formar uma explicação exaustiva. As perguntas mais comuns são:

PARA QUEM, POR QUE e COMO o modelo que está sendo examinado produz suas previsões/inferências?

Problemas distintos, tipos distintos de usuários e comportamentos distintos exigem explicações distintas. Outras perguntas podem surgir, exigindo respostas diferentes, portanto, diferentes tipos de explicações.

O Modelo de ML (núcleo da IA)

É um algoritmo treinado com dados para reconhecer padrões e gerar previsões ou classificações.

Exemplos:

- Redes neurais para reconhecimento de imagens;
- Regressões para prever preços;
- Modelos de recomendação para indicar a melhor escolha baseada na suas indicações;

Saída do modelo: é a **previsão** feita a partir dos dados de entrada. Por exemplo, “este cliente tem alta probabilidade de cancelar o contrato”.

Estrutura de uma Explicação



O método de XAI

É o conjunto de técnicas que tornam o funcionamento do modelo mais transparente. Ele não altera a previsão em si, mas ajuda a explicar como e por que o modelo chegou àquela conclusão.

Métodos comuns:


- **LIME (Local Interpretable Model-agnostic Explanations)**: cria explicações locais para cada previsão, mostrando quais variáveis mais influenciaram;
- **SHAP (SHapley Additive exPlanations)**: baseado em teoria dos jogos, calcula a contribuição de cada variável para o resultado;
- **Feature importance**: destaca quais atributos do conjunto de dados têm maior peso no modelo.

As duas saídas da IA explicável

- **Previsões:** resultado direto do modelo (ex.: diagnóstico médico sugerido, risco de crédito);
- **Explicações:** resultado do método de XAI, que mostra ao usuário os fatores determinantes da previsão.

Essa dupla saída é essencial para aumentar a confiança do usuário, facilitar auditorias e atender requisitos regulatórios (como na área financeira ou de saúde).

Componentes da Inteligência Artificial Explicável (XAI) e possíveis partes interessadas



Estrutura de uma Explicação



Interface gráfica

Para que previsões e explicações sejam úteis, elas precisam ser apresentadas de forma clara. Normalmente, usa-se uma interface visual que mostra o resultado da previsão.

Estes resultados podem ser apresentados em forma de gráficos ou indicadores que explicam os fatores mais relevantes e apresentam também possibilidade de interação, permitindo ao usuário explorar diferentes cenários.

Isso aproxima a IA do usuário final, tornando-a poderosa, compreensível e confiável. Essa arquitetura é o que permite que sistemas de IA sejam não apenas eficazes, mas também transparentes e responsáveis.

Cenário: Diagnóstico de doenças cardíacas

Um hospital utiliza um sistema de IA para prever se um paciente tem risco elevado de desenvolver uma doença cardíaca.

1. Modelo de aprendizado

O modelo foi treinado com milhares de registros médicos contendo informações como idade, pressão arterial, colesterol, histórico familiar e hábitos de vida.

Quando um novo paciente faz exames, o modelo gera uma **previsão**: por exemplo, “risco alto de doença cardíaca”.

2. Método de XAI

A explicabilidade entra para que médicos e pacientes confiem na previsão, usando técnicas como **SHAP**, o sistema mostra quais variáveis mais influenciaram o resultado.

Exemplo:

Colesterol elevado (+25% de contribuição para o risco)

Pressão arterial alta (+20%)

Idade (+15%)

Sedentarismo (+10%)

3. Interface gráfica - Médico

O médico vê em uma tela um gráfico de barras indicando o peso de cada variável.



4. Interface gráfica - Paciente

O paciente recebe uma versão simplificada, mostrando que hábitos de vida e exames alterados foram os principais motivos.



Ambos podem entender **não apenas o que o modelo prevê, mas também por que prevê.**



Benefícios da explicabilidade em IA

- **Confiança:** o médico não precisa aceitar cegamente a previsão; ele vê os fatores que a sustentam.
- **Tomada de decisão:** o paciente pode ser orientado a mudar hábitos (ex.: dieta e exercícios) com base nos fatores explicados.
- **Regulação:** em áreas sensíveis como saúde, é obrigatório justificar decisões automatizadas — a explicabilidade cumpre esse papel.

Referências

ARRIETA, Alejandro Barredo et al. *Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI*. 2019. Disponível em: <https://arxiv.org/abs/1910.10045>.

LENT, M. van; FISHER, W.; MANCUSO, M. An explainable artificial intelligence system for small-unit tactical behavior. In: ***Proceedings of the 16th Conference on Innovative Applications of Artificial Intelligence***. [S.l.: s.n.], 2004. p. 900–907.

SWARTOUT, W. R.; MOORE, J. D. *Explanation in expert systems: A survey*. Los Angeles, CA, USA, 1988.

DWIVEDI, R.; DAVE, D.; NAIK, H.; SINGHAL, S.; OMER, R.; PATEL, P.; QIAN, B.; WEN, Z.; SHAH, T.; MORGAN, G.; RANJAN, R. *Explainable ai (xai): Core ideas, techniques, and solutions*. Association for Computing Machinery, New York, NY, USA, v. 55, n. 9, jan. 2023. ISSN 0360-0300