



Requisitos de explicabilidade para usuários finais a partir do framework de prototipação EUCA

Posicionamento de onde ocorre o experimento



COMPONENTES DE UM SISTEMA DE IA




| Key Stages of AI Model Development Lifecycle



Principais diferenças

Software tradicional x software com IA

- Software tradicional □ determinístico e transparente.
 - regras deterministas, rastreáveis e transparentes, com saídas previsíveis.
- Software com IA □ maioria das vezes tem caráter emergente e probabilístico
 - comportamento emergente, não programado diretamente, resultado probabilístico e muitas vezes opaco.
- Por isso, a confiança, a segurança, a justiça, o aprendizado e a comunicação com diferentes públicos passam a depender fortemente de recursos de explicabilidade e transparência do modelo.



IA: Emergente e Probabilística

Saida Certa

Regras Claras



**Software Tradicional:
Determinista e Transparente**

- Os sistemas de IA têm natureza estatística/probabilística: aprendem a partir de grandes volumes de dados, de modo que viés e ruído nesses dados se tornam fontes centrais de erro, injustiça e riscos de generalização.
- As saídas são intrinsecamente incertas e sensíveis ao contexto, refletindo distribuições probabilísticas aprendidas e podendo produzir resultados surpreendentes ou contraintuitivos, por vezes arriscados.
- Nesses cenários, explicabilidade e interpretabilidade são cruciais para compreender padrões e decisões, especialmente em aplicações de alto impacto.

Aspecto	Sistema de IA	Software tradicional
Natureza	- Emergentes (aprendem comportamentos não previstos pelos desenvolvedores, surgindo da interação entre dados e algoritmos). Resultados podem ser surpreendentes, contraintuitivos ou até arriscados - Probabilística	- Determinista e - Transparente
Base de funcionamento	Dados (aprendizado)	Regras (programação)
Fonte de erro	Viés ou ruído nos dados	Bug ou lógica incorreta
Explicabilidade	Necessária para entender padrões e decisões	Naturalmente rastreável no código
Saída	Incerta, dependente do contexto (probabilística).	Certa, previsível e replicável
Trade-offs de objetivos	- Emergentes do processo de treinamento e dos dados. - São implícitos e dinâmicos. - São mais difíceis de prever e controlar.	Definidos explicitamente pelos programadores. São conscientes e rastreáveis.

- Em sistemas baseados em IA , muitos trade-offs entre objetivos como desempenho, precisão, custo e justiça emergem do processo de treinamento e dos dados, sendo em grande parte implícitos e dinâmicos;
- O contexto, os dados e as prioridades mudam ao longo do tempo, e a IA precisa se adaptar a isso para continuar útil e segura.

- **Principais motivos dos trade-offs serem dinâmicos**

- **Mudança de dados e ambiente:** Sistemas de IA são treinados e operam sobre grandes volumes de dados; quando o ambiente muda (novos padrões de uso, novas fraudes, novas doenças etc.), os objetivos intermediários precisam ser ajustados para continuar produzindo boas decisões;
- **Requisitos de negócio:** Empresas alteram estratégias, metas e restrições (custo, risco, qualidade de serviço), então os objetivos operacionais da IA (maximizar conversão, reduzir fraudes, priorizar experiência do usuário etc.) também precisam mudar.
- **Aspectos éticos e culturais:** Normas legais, expectativas sociais e valores éticos evoluem, e sistemas verdadeiramente éticos precisam ajustar dinamicamente seus objetivos para continuar alinhados ao comportamento humano aceitável.

Exemplo:

Um sistema de recomendação de filmes: no início, o objetivo pode ser “maximizar cliques”; depois, percebe-se que isso gera vício ou insatisfação, e o objetivo é alterado para “equilibrar engajamento com bem-estar do usuário e diversidade de conteúdo”. O sistema continua sendo o mesmo, mas a função objetivo muda conforme novos dados, novas preocupações éticas e novas metas de negócio aparecem